# Análise de preços de combustíveis

1º Semestre - Brasil



### Sumário

01 Dataset

Sobre o que se trata o dataset e seus dados

02 Desenvolvimento

Metodologia utilizada no projeto 03 Resultados

Alguns dos exemplos obtidos através do projeto

04 Referências

Agradecimentos e referências utilizadas







# **Dataset**

Contém preços de compra e venda diversos combustíveis automotivos no período do primeiro semestre de 2022.

"regiao", "estado", "municipio", "revenda", "cnpj\_da\_revenda", "nome\_da\_rua", "numero\_rua", "complemento", "bairro", "cep", "produto", "data\_da\_coleta", "valor\_de\_venda", "valor\_de\_compra", "unidade\_de\_medida", "bandeira"



# MongoDB

```
services:
  mongodb:
    container_name: mongodb
    image: mongo
    restart: always
  environment:
        - MONGO_INITDB_DATABASE=br_fuel_prices
        - MONGO_INITDB_ROOT_USERNAME=br_fuel_prices
        - MONGO_INITDB_ROOT_PASSWORD=br_fuel_prices
        networks:
        hadoop_network:
        ipv4_address: 172.18.0.10
```

docker-compose.yml



# **MongoDB**

```
. .
 import csv
from pymongo import MongoClient
client = MongoClient('mongodb://br_fuel_prices:br_fuel_prices@172.18.0.10:27017')
db = client.br_fuel_prices
fuel_prices = db.fuel_prices
with open('/root/precos-semestrais-ca-2022-01.csv', 'r') as csvfile:
["regiao", "estado", "municipio", "revenda", "cnpj_da_revenda", "nome_da_rua", "numero_rua", "complemento", "ba
irro", "cep", "produto", "data_da_coleta", "valor_de_venda", "valor_de_compra", "unidade_de_medida", "bandeira
  reader = csv.reader(csvfile, delimiter=';')
  next(reader)
   for row in reader:
    doc = \{\}
        doc[header[n]] = row[n]
    fuel_prices.insert_one(doc)
```

apps/seed\_db.py

### Spark

```
• • •
from pyspark.conf import SparkConf
from pyspark.context import SparkContext
from pyspark.sql import SparkSession
def init_spark():
    password = 'br_fuel_prices'
    user = 'br_fuel_prices'
    host = '172.18.0.10'
    db auth = ''
    database = 'br fuel prices'
    collection = 'fuel_prices'
     "mongo_conn =f"mongdbo://{tase}}:{passworld?@{nost}?2701//{db_auth}"
     conf.set("spark.mongodb.read.connection.uri", mongo_conn)
     conf.set("spark.mongodb.read.database", database)
     conf.set("spark.mongodb.read.collection", collection)
     conf.set("spark.mongodb.write.connection.uri", mongo_conn)
     conf.set("spark.mongodb.write.datahpase", datahpase
          .appName('br_fuel_prices') \
                        apps/init_spark.py
```



## Spark

```
from init_spark import init_spark

spark = init_spark()

df = spark.read.format("mongodb").load()

# Filtra por municipio e produto

df = df.filter((df['municipio'] == 'NATAL') & (df['produto'] == 'GASOLINA'))

# Mapeia e converte valores do produto de string para float

df = df.rdd.map(lambda x: (x.municipio, float(x.valor_de_venda.replace(",", ".")))).toDF(["municipio", "valor"])

# Obtem a media dos valores para o municipio em questao

df = df.groupBy("municipio").avg("valor")

df.show()
```



apps/average\_price\_by\_city.py



# Preço médio de gasolina por município

#### Comando

spark-submit --packages org.mongodb.spark:mongo-spark-connector:10.0.5 apps/average\_price\_by\_city.py

```
+----+

|municipio| avg(valor)|

+----+

| NATAL|7.413106060606032|

+----+
```



# Maior preço de gasolina no semestre

#### Comando

spark-submit --packages org.mongodb.spark:mongo-spark-connector:10.0.5 apps/highest\_price.py

```
+-----+
| produto|max(valor)|estado| municipio|
+-----+
|GASOLINA| 8.99| RJ|RIO DE JANEIRO|
+-----+
```



# Menor preço de gasolina por região

#### Comando

spark-submit --packages org.mongodb.spark:mongo-spark-connector:10.0.5 apps/lowest\_price\_by\_region.py







### Referências

- Docker Hadoop Cluster por cmdviegas
- 10 Sem 2022 -Combustíveis Automotivos por dados.gov.br

CREDITS: This presentation template was created by **Slidesgo**, including icons by **Flaticon** and infographics & images by **Freepik**